Nombre: Ivan Arturo Cabrera Bravo	**Matrícula**: AL07182813
Nombre del curso: Gestión de Proyectos de Inteligencia Artificial.	**Nombre del profesor:** Luis Ariel Vázquez Piña.
Módulo: 2	**Actividad 5**.
Fecha: 18 de Octubre2026	

Bibliografía:

Dhakadd, S. (s. f.). Bank customer churn prediction [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/shantanudhakadd/bank-customer-churn-prediction

Breck, E., Cai, S., Nielsen, E., Salib, M., & Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. IEEE International Conference on Big Data.

Chen, T., et al. (2020). MLflow: A platform for managing the machine learning lifecycle. https://mlflow.org/

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Sculley, D., et al. (2015). Hidden technical debt in machine learning systems. Advances in Neural Information Processing Systems, 28.

Actividad 5. Preparación de datos, optimización de modelos y trazabilidad con MLflow

Introducción y planteamiento del problema

La pérdida de clientes puede generar costos de adquisición, afectar ingresos recurrentes y debilitar las relaciones comerciales. En un contexto bancario, una clasificación anticipada permite priorizar acciones de retención; sin embargo, una predicción equivocada también tiene costos. Por ello, el ejercicio no se limita a maximizar accuracy: considera el equilibrio entre identificación de abandonos, falsas alarmas y capacidad de reproducir los experimentos.

Objetivos y alcance

Objetivo general: construir, comparar y documentar dos modelos de clasificación binaria sobre un conjunto público de clientes bancarios, registrando su configuración, métricas y artefactos de manera trazable.

Objetivos específicos: auditar y versionar los datos; entrenar regresión logística y Random Forest con validación cruzada; comparar resultados en un conjunto reservado; explorar umbrales e importancia de variables; registrar experimentos en MLflow y discutir deuda técnica.

Alcance: prototipo académico sin despliegue ni decisiones automatizadas sobre clientes reales. No se infiere causalidad ni se valida la generalización a otras instituciones o periodos.

Datos, limpieza y control de calidad

Se utilizó el conjunto Bank Customer Churn Prediction (Kaggle, shantanudhakadd/bank-customer-churn-prediction), con 10,000 registros. La variable objetivo Exited indica abandono. La versión limpia conserva 10,000 registros y no reporta duplicados eliminados. Se excluyeron RowNumber, CustomerId y Surname por su naturaleza identificadora o administrativa. Los valores faltantes se tratan mediante imputación ajustada dentro del pipeline de entrenamiento, para reducir fuga de información.

El conjunto tiene 7,963 casos de permanencia y 2,037 de abandono (20.37%). Esta asimetría exige interpretar accuracy junto con precision, recall, F1 y ROC-AUC. Se guardaron hashes SHA-256 para los archivos original y limpio, lo que permite detectar alteraciones en las versiones de los datos.

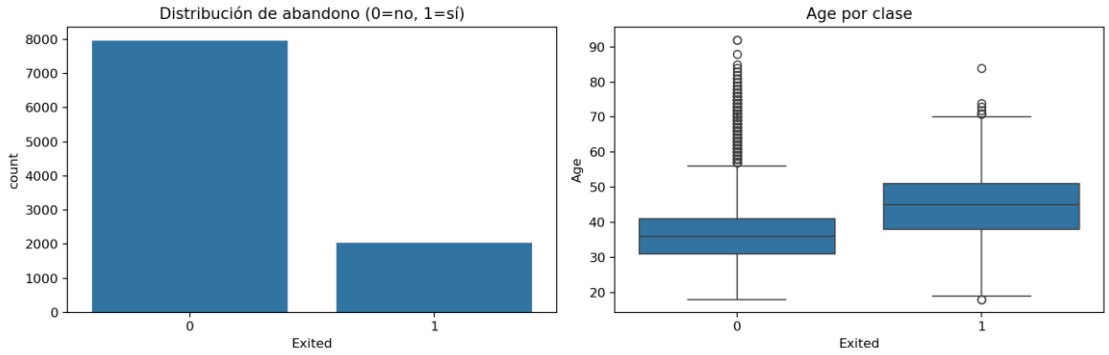


Figura 1. Diagnóstico visual de la calidad y distribución de los datos, exportado por el notebook.

Metodología de entrenamiento y reproducibilidad

Se compararon regresión logística, como referencia lineal interpretable, y Random Forest, como ensamble no lineal. El notebook emplea GridSearchCV con validación cruzada de cinco particiones para seleccionar hiperparámetros, evitando utilizar la partición de prueba durante la búsqueda. La transformación de variables forma parte del pipeline para impedir que la estandarización o la imputación aprendan información de prueba.

La regresión logística seleccionó C=1 y class_weight=balanced. Random Forest seleccionó 200 árboles, profundidad máxima de 10, mínimo de 3 muestras por hoja y class_weight=balanced. Estos parámetros equilibran flexibilidad del modelo, regularización y atención al desbalance, pero su conveniencia debe juzgarse por el desempeño observado.

5. Resultados comparativos

Indicador	Regresión logística	Random Forest
accuracy	0.7135	0.8365
precision	0.3872	0.5862
recall	0.7002	0.6683
f1	0.4987	0.6246
roc_auc	0.7772	0.8614
cv_roc_auc_mean	0.7662	0.8574
cv_roc_auc_std	0.0205	0.0126

Random Forest logra mayor accuracy (0.8365), precision (0.5862), F1 (0.6246) y ROC-AUC (0.8614). La regresión logística presenta recall ligeramente superior (0.7002 frente a 0.6683). La diferencia en ROC-AUC de prueba es aproximadamente 0.0843 a favor de Random Forest. La desviación estándar de ROC-AUC en validación cruzada también es menor para Random Forest (0.0126 frente a 0.0205), aunque esto no garantiza estabilidad temporal.

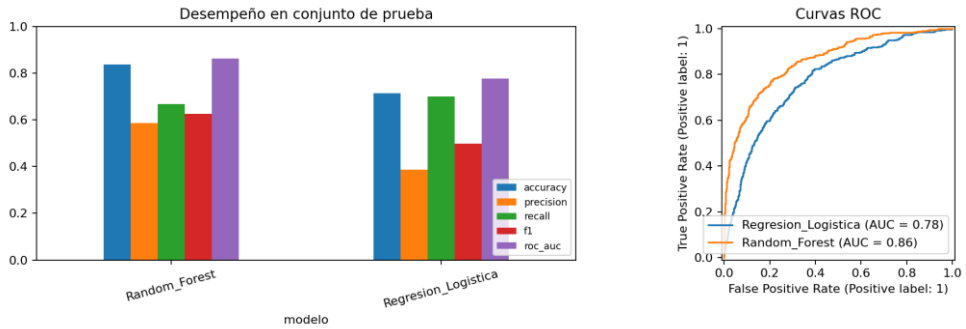


Figura 2. Comparación de métricas entre los algoritmos, obtenida de la ejecución.

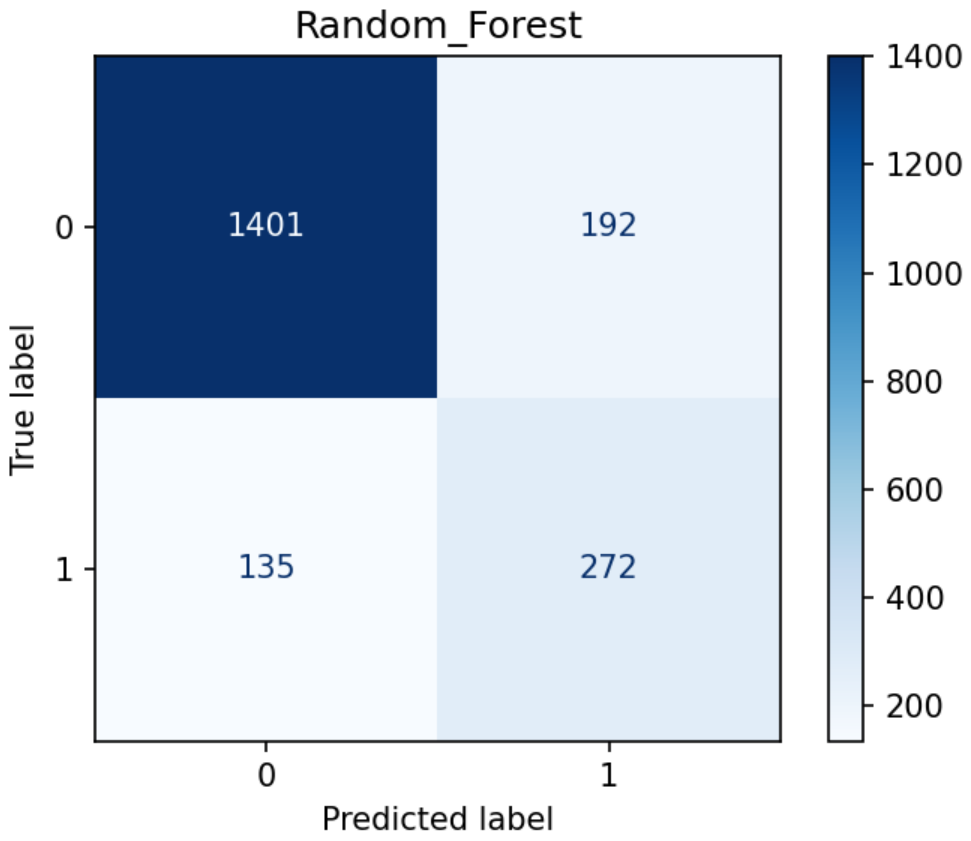


Figura 3. Matriz de confusión de Random Forest para identificar aciertos y errores por clase.

Evaluación exploratoria de umbrales

El umbral predeterminado de 0.50 no es necesariamente el óptimo para cualquier política de retención. En Random Forest, reducirlo a 0.30 eleva recall a 0.8722, pero reduce precision a 0.3793; en 0.40, recall es 0.7740 y precision 0.4817. Con 0.50, F1 alcanza 0.6246; con 0.60, precision sube a 0.6832, pero recall cae a 0.5405.

Advertencia metodológica: estos valores fueron explorados en el conjunto de prueba. Para seleccionar un umbral operativo sin sesgo de evaluación se necesitaría una partición de validación adicional o predicciones fuera de muestra, seguida de una prueba final independiente. No se presenta el umbral 0.50 como una optimización estadísticamente confirmada.

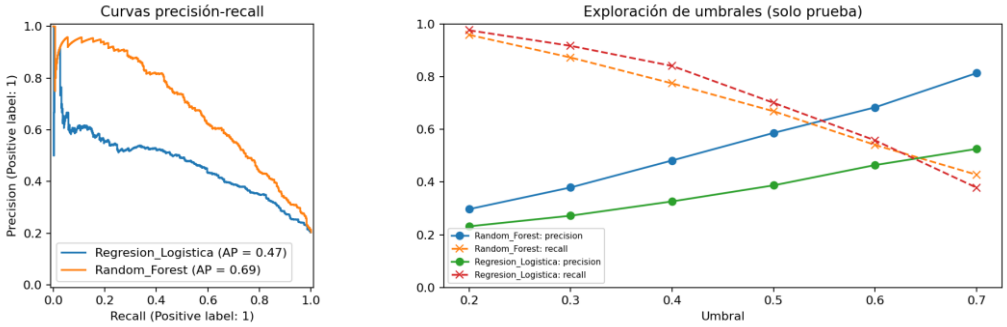


Figura 4. Relación precision-recall para los umbrales explorados.

Interpretabilidad: importancia por permutación

La importancia por permutación mide cuánto disminuye ROC-AUC cuando se altera una variable, manteniendo las demás constantes. En Random Forest, Age (0.1238) y NumOfProducts (0.1024) destacan claramente, seguidas por Balance (0.0297) e IsActiveMember (0.0292). Esto indica dependencia predictiva del modelo, no una relación causal. Variables correlacionadas pueden repartir su contribución y algunas importancias cercanas a cero o negativas pueden reflejar ruido.

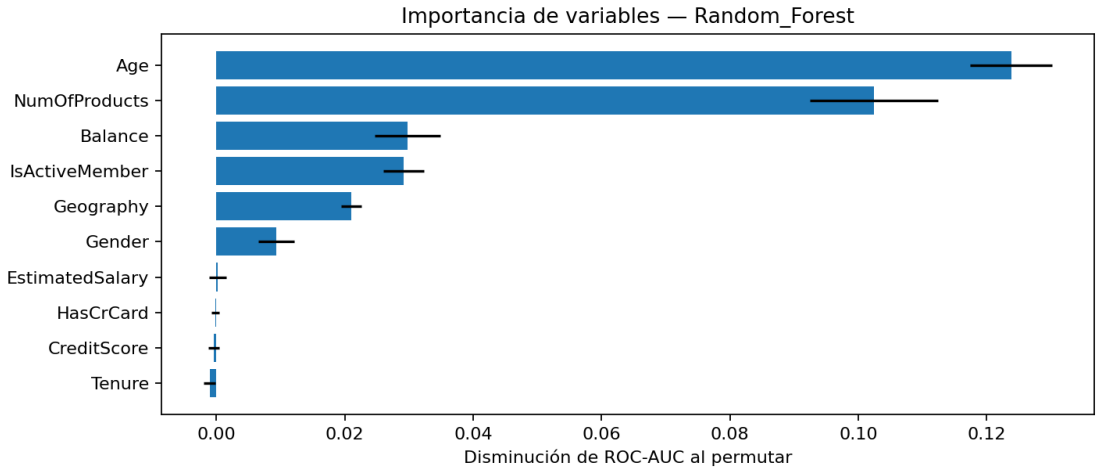


Figura 5. Importancia por permutación en Random Forest.

Registro experimental con MLflow

Se utilizó MLflow con almacenamiento de seguimiento SQLite y registro de parámetros, métricas, búsquedas y artefactos. El paquete final incluye mlflow.db, directorios de artefactos, modelos Skops y copias Joblib, además de CSV y gráficas. Este diseño facilita auditar qué configuración generó cada resultado. La serialización requiere cautela: los modelos solo deben cargarse desde fuentes confiables y con dependencias compatibles.

El hash de los datasets y el manifiesto de evidencias fortalecen la integridad, pero para una reproducción integral en otra máquina conviene fijar versiones de dependencias, documentar semilla, ruta de datos y ejecución, y comprobar la carga de modelos fuera del entorno original.

Análisis de deuda técnica y propuesta MLOps

La principal deuda técnica es que los datos corresponden a una muestra estática, sin validación temporal ni evaluación prospectiva. También faltan pruebas sistemáticas de calibración, equidad por segmentos, robustez ante cambios de distribución y costos de intervención. En producción, estos riesgos podrían provocar deterioro silencioso del modelo y decisiones de retención ineficientes.

Como medidas MLOps se propone: versionar datos y código con etiquetas de liberación; establecer pruebas de esquema, nulos y rangos; comparar métricas de producción con una línea base; monitorear drift y desempeño por segmento; evaluar calibración de probabilidades; registrar revisiones humanas y costos; definir criterios de

reentrenamiento y reversión; mantener permisos y protección de datos. Antes de cualquier despliegue, se requiere validación institucional y análisis de riesgos.

Conclusiones y reflexión

La evidencia favorece a Random Forest para discriminar abandono y equilibrar precision y recall en el umbral estándar. No obstante, la regresión logística conserva una ventaja de sensibilidad, útil cuando omitir a un cliente en riesgo resulta especialmente costoso. La selección definitiva debe responder a objetivos operativos explícitos y a costos medidos, no solo a una métrica agregada.

El ejercicio muestra que entrenar un modelo es solo una parte de un proyecto de inteligencia artificial. Registrar parámetros, conservar artefactos y documentar decisiones permite revisar los resultados y facilita que otras personas reproduzcan el análisis. La principal lección técnica es separar lo demostrado por los datos de lo que todavía exige validación adicional.