Nombre: Ivan Arturo Cabrera Bravo	**Matrícula**: AL07182813
Nombre del curso: Gestión de Proyectos de Inteligencia Artificial.	**Nombre del profesor:** Luis Ariel Vázquez Piña.
Módulo: 2	**Actividad 5**.
Fecha: 18 de Octubre2026	

Bibliografía:

Dhakadd, S. (s. f.). Bank customer churn prediction [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/shantanudhakadd/bank-customer-churn-prediction

Breck, E., Cai, S., Nielsen, E., Salib, M., & Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. IEEE International Conference on Big Data.

Chen, T., et al. (2020). MLflow: A platform for managing the machine learning lifecycle. https://mlflow.org/

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Sculley, D., et al. (2015). Hidden technical debt in machine learning systems. Advances in Neural Information Processing Systems, 28.

Actividad 5. Preparación de datos, optimización de modelos y trazabilidad con MLflow

Introducción y planteamiento del problema

La pérdida de clientes puede generar costos de adquisición, afectar ingresos recurrentes y debilitar las relaciones comerciales. En un contexto bancario, una clasificación anticipada permite priorizar acciones de retención; sin embargo, una predicción equivocada también tiene costos. Por ello, el ejercicio no se limita a maximizar accuracy: considera el equilibrio entre identificación de abandonos, falsas alarmas y capacidad de reproducir los experimentos.

Objetivos y alcance

Objetivo general: construir, comparar y documentar dos modelos de clasificación binaria sobre un conjunto público de clientes bancarios, registrando su configuración, métricas y artefactos de manera trazable.

Objetivos específicos: auditar y versionar los datos; entrenar regresión logística y Random Forest con validación cruzada; comparar resultados en un conjunto reservado; explorar umbrales e importancia de variables; registrar experimentos en MLflow y discutir deuda técnica.

Alcance: prototipo académico sin despliegue ni decisiones automatizadas sobre clientes reales. No se infiere causalidad ni se valida la generalización a otras instituciones o periodos.

Datos, limpieza y control de calidad

Se utilizó el conjunto Bank Customer Churn Prediction (Kaggle, shantanudhakadd/bank-customer-churn-prediction), con 10,000 registros. La variable objetivo Exited indica abandono. La versión limpia conserva 10,000 registros y no reporta duplicados eliminados. Se excluyeron RowNumber, CustomerId y Surname por su naturaleza identificadora o administrativa. Los valores faltantes se tratan mediante imputación ajustada dentro del pipeline de entrenamiento, para reducir fuga de información.

El conjunto tiene 7,963 casos de permanencia y 2,037 de abandono (20.37%). Esta asimetría exige interpretar accuracy junto con precision, recall, F1 y ROC-AUC. Se guardaron hashes SHA-256 para los archivos original y limpio, lo que permite detectar alteraciones en las versiones de los datos.

La revisión inicial permitió identificar una característica importante del conjunto de datos: aproximadamente uno de cada cinco registros corresponde a clientes que abandonaron la institución. Esta distribución obliga a evaluar cuidadosamente los resultados, ya que un modelo que predijera principalmente la permanencia podría obtener una exactitud aparentemente favorable sin identificar adecuadamente a los clientes que abandonan.
Por esta razón, la preparación de los datos no se limitó a conservar los registros disponibles. También se consideró la naturaleza de las variables, la exclusión de identificadores sin utilidad predictiva directa y la aplicación del preprocesamiento dentro de los pipelines. Esta última decisión es relevante porque evita que las transformaciones aprendan información del conjunto de prueba durante el entrenamiento.

Adicionalmente, la conservación de los archivos originales y depurados, junto con sus identificadores SHA-256, permite comprobar que los experimentos se realizaron sobre versiones específicas de los datos. Esto contribuye a la trazabilidad y reduce la

posibilidad de comparar resultados obtenidos a partir de archivos diferentes sin advertirlo.

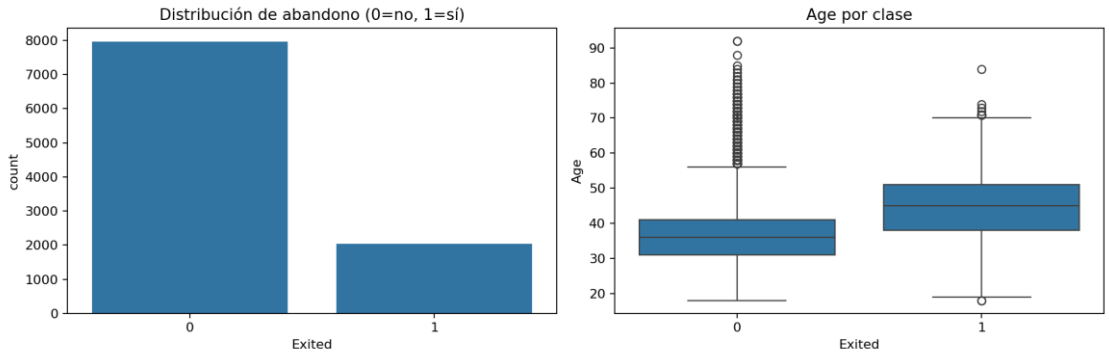


Figura 1. Diagnóstico visual de la calidad y distribución de los datos, exportado por el notebook.

Metodología de entrenamiento y reproducibilidad

Se compararon regresión logística, como referencia lineal interpretable, y Random Forest, como ensamble no lineal. El notebook emplea GridSearchCV con validación cruzada de cinco particiones para seleccionar hiperparámetros, evitando utilizar la partición de prueba durante la búsqueda. La transformación de variables forma parte del pipeline para impedir que la estandarización o la imputación aprendan información de prueba.

La regresión logística seleccionó C=1 y class_weight=balanced. Random Forest seleccionó 200 árboles, profundidad máxima de 10, mínimo de 3 muestras por hoja y class_weight=balanced. Estos parámetros equilibran flexibilidad del modelo, regularización y atención al desbalance, pero su conveniencia debe juzgarse por el desempeño observado.

Resultados comparativos

Indicador	Regresión logística	Random Forest
accuracy	0.7135	0.8365
precision	0.3872	0.5862
recall	0.7002	0.6683
f1	0.4987	0.6246
roc_auc	0.7772	0.8614
cv_roc_auc_mean	0.7662	0.8574
cv_roc_auc_std	0.0205	0.0126

La selección de Regresión Logística y Random Forest permitió comparar dos enfoques con características distintas. La Regresión Logística funciona como una referencia estadística relativamente sencilla de interpretar, mientras que Random Forest combina múltiples árboles de decisión y puede representar relaciones no lineales e interacciones entre variables.

Para evitar que la comparación dependiera únicamente de configuraciones elegidas de manera arbitraria, se utilizó GridSearchCV como procedimiento de búsqueda de hiperparámetros. Este mecanismo evalúa diferentes combinaciones mediante

validación cruzada, lo que permite seleccionar configuraciones con base en un criterio cuantitativo.

La validación cruzada estratificada de cinco particiones también resulta importante por el desbalance de la variable objetivo, ya que procura mantener una proporción semejante de ambas clases en las particiones. Aunque este procedimiento no elimina todos los riesgos de sobreajuste, proporciona una evaluación más sólida que utilizar una sola división para seleccionar los hiperparámetros.

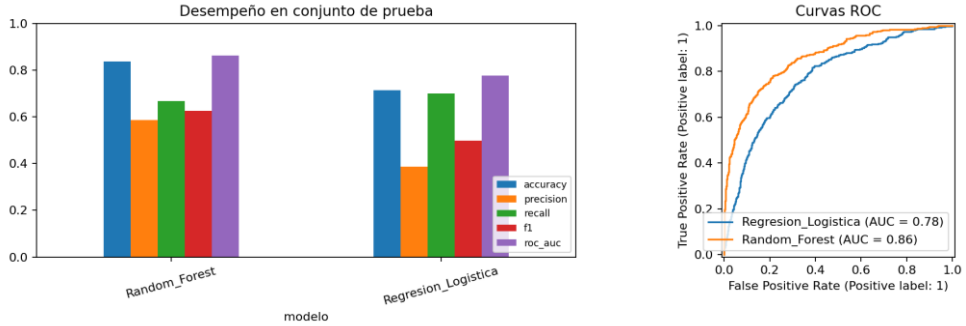


Figura 2. Comparación de métricas entre los algoritmos, obtenida de la ejecución.

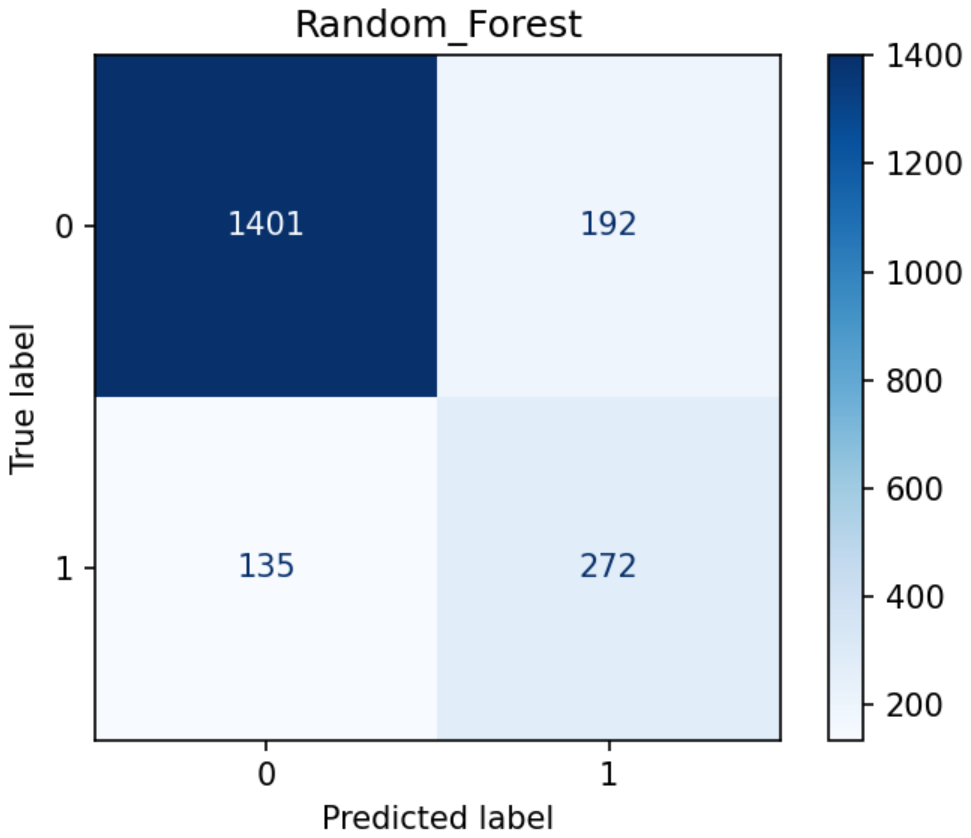


Figura 3. Matriz de confusión de Random Forest para identificar aciertos y errores por clase.

Los resultados muestran diferencias relevantes entre los algoritmos. Random Forest alcanzó un ROC-AUC de 0.8614, frente a 0.7772 de la Regresión Logística, lo que representa una ventaja aproximada de 0.0842 puntos. Esta diferencia sugiere una mejor

capacidad para distinguir entre clientes que abandonan y clientes que permanecen, considerando distintos umbrales de decisión.
La matriz de confusión de Random Forest permite precisar el alcance de esta mejora: de 1,593 casos de permanencia en la muestra de prueba, 1,401 se clasificaron correctamente y 192 generaron falsas alertas. Entre 407 casos de abandono, el modelo identificó 272 y dejó sin detectar 135. En términos prácticos, estos errores muestran por qué una métrica global favorable no elimina el riesgo de omitir clientes que podrían requerir una intervención de retención.

La diferencia también se observa en F1-score: Random Forest obtuvo 0.6246 y la Regresión Logística 0.4987. Dado que esta métrica combina precisión y sensibilidad, el resultado indica un equilibrio más favorable entre la identificación de abandonos y la generación de alertas incorrectas.

Sin embargo, la Regresión Logística alcanzó una sensibilidad de 0.7002, ligeramente superior al 0.6683 de Random Forest. Este hallazgo es importante porque demuestra que la elección del modelo no debe depender exclusivamente de una clasificación general de ganador y perdedor. Si el objetivo principal fuera detectar la mayor cantidad posible de abandonos, incluso a costa de generar más falsas alarmas, la sensibilidad tendría un peso especial en la decisión.

En consecuencia, Random Forest constituye la alternativa más sólida para el objetivo comparativo de este ejercicio, pero su adopción en un escenario real requeriría establecer previamente los costos asociados con los falsos positivos y falsos negativos.

Evaluación exploratoria de umbrales

El análisis de umbrales permitió observar que el comportamiento del clasificador cambia dependiendo del punto utilizado para transformar las probabilidades en decisiones. Con Random Forest, un umbral de 0.30 produjo una sensibilidad aproximada de 0.8722, pero una precisión de 0.3793. En contraste, al aumentar el umbral a 0.60, la precisión alcanzó 0.6832, mientras que la sensibilidad disminuyó a 0.5405.

Esta relación representa una decisión operativa relevante. Un umbral reducido permitiría identificar más casos potenciales de abandono, aunque también incrementaría las alertas sobre clientes que realmente permanecerían. Por otra parte, un umbral elevado concentraría las alertas en predicciones de mayor confianza, pero dejaría sin identificar una proporción más alta de abandonos.

Es importante señalar que los umbrales explorados se analizaron sobre el conjunto de prueba. Por tanto, estos resultados deben interpretarse como evidencia exploratoria y no como una selección definitiva del umbral operativo. Para una implementación real sería necesario establecer el umbral utilizando datos de validación independientes y comprobar posteriormente su desempeño sobre información no utilizada durante la selección.

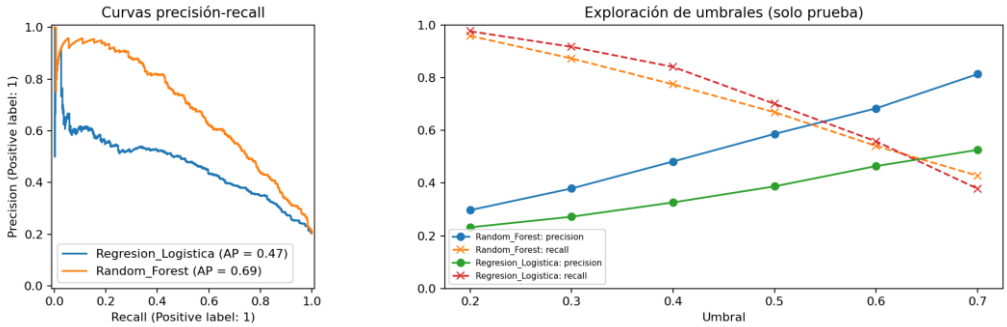


Figura 4. Relación precision-recall para los umbrales explorados.

Interpretabilidad: importancia por permutación

Los resultados de importancia por permutación muestran que la edad y el número de productos contratados son las variables de mayor contribución al desempeño predictivo de Random Forest. Sus valores aproximados de 0.1238 y 0.1024 indican que alterar estas características provoca una reducción considerable del ROC-AUC en comparación con otras variables.

Desde una perspectiva de análisis de negocio, estos resultados permiten identificar características que merecerían una investigación más detallada. No obstante, sería incorrecto afirmar que la edad o el número de productos causan directamente el abandono. La importancia por permutación mide la dependencia del modelo respecto de una variable, no demuestra causalidad ni establece por sí misma una explicación del comportamiento de los clientes.

Este ejercicio también evidencia la necesidad de combinar desempeño predictivo con interpretabilidad, especialmente en aplicaciones relacionadas con servicios financieros.

Estas observaciones ayudan a interpretar la figura 5 como un análisis de sensibilidad del modelo ante la alteración de sus variables, y no como una justificación para tomar decisiones comerciales basadas únicamente en la edad o en la cantidad de productos contratados.

Antes de utilizar estas predicciones para orientar decisiones reales, sería necesario revisar la estabilidad de las variables relevantes y evaluar posibles diferencias de desempeño entre grupos de clientes.

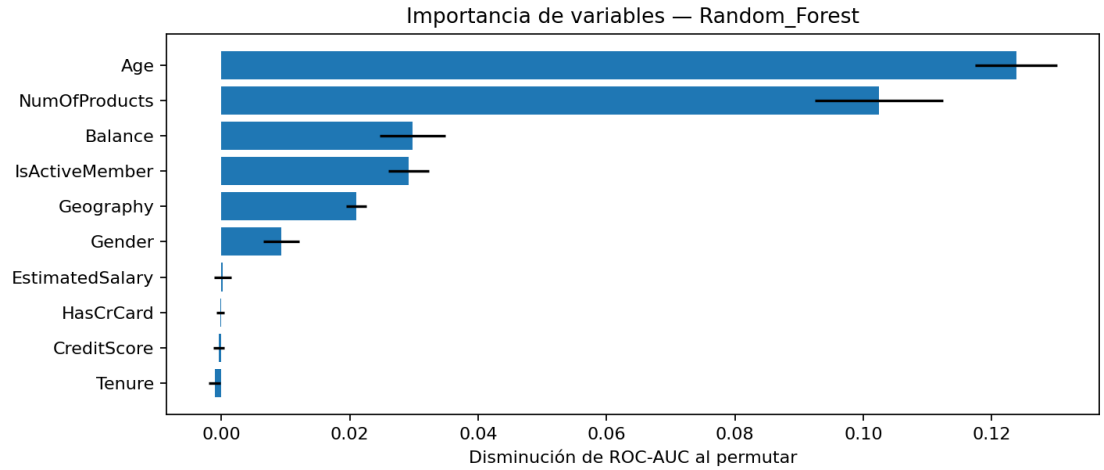


Figura 5. Importancia por permutación en Random Forest.

Registro experimental con MLflow

La incorporación de MLflow permitió organizar el proceso experimental más allá de la ejecución del código. El registro de parámetros, métricas y artefactos facilita relacionar cada resultado con la configuración utilizada para obtenerlo. Esto es especialmente importante cuando se comparan varios algoritmos y combinaciones de hiperparámetros, ya que reduce la dependencia de anotaciones manuales o resultados dispersos.

El uso de SQLite como almacenamiento del seguimiento experimental y la exportación de los artefactos proporcionan un respaldo consultable del trabajo realizado. Asimismo, la conservación de modelos serializados, tablas y visualizaciones permite revisar diferentes etapas del experimento sin depender exclusivamente de las salidas visibles en Google Colab.

Sin embargo, conservar los artefactos no garantiza por sí solo una reproducción idéntica. También es necesario considerar las versiones de las bibliotecas, las semillas aleatorias, la disponibilidad del conjunto de datos y las características del entorno de ejecución. Por ello, la documentación del repositorio y el archivo de dependencias complementan el seguimiento realizado mediante MLflow.

La trazabilidad lograda con MLflow y el repositorio de GitHub permite reconstruir las decisiones principales del experimento, pero no equivale a contar con un sistema de operación continua. Para avanzar hacia un uso institucional harían falta controles automatizados, responsables definidos y criterios verificables de aceptación del modelo.

En conjunto, estas prácticas constituyen una aproximación académica a MLOps, centrada en la trazabilidad, la organización de experimentos y la posibilidad de auditar los resultados antes de plantear una implementación productiva.

El primer riesgo se relaciona con la representatividad: una muestra pública y estática puede reflejar patrones que cambien con el tiempo o que no se reproduzcan en otra población bancaria. Un segundo riesgo surge de la calidad de las probabilidades estimadas: un ROC-AUC elevado no demuestra que una probabilidad de abandono del 70 % corresponda efectivamente a siete abandonos por cada diez casos semejantes. La calibración debería comprobarse por separado. Por último, el desempeño promedio puede ocultar diferencias entre segmentos; por ello, antes de

cualquier aplicación real habría que analizar posibles disparidades, siempre con criterios de privacidad y pertinencia.

Análisis de deuda técnica y propuesta MLOps

Desde la gestión del proyecto, estas actividades también requieren asignar responsabilidades: el equipo de datos validaría la fuente y las transformaciones; el equipo de modelado comprobaría métricas y sesgos; y la instancia responsable del negocio determinaría el costo aceptable de falsas alertas y abandonos no detectados. Este esquema es una propuesta de evolución MLOps, no una capacidad implementada en el prototipo académico.

Una ruta de mejora razonable comenzaría por establecer una línea base con los resultados actuales y registrar la versión del conjunto de datos, del código y de las dependencias. Después se definirían pruebas automáticas de integridad y esquema antes de cada entrenamiento, además de una evaluación periódica de calidad, calibración y estabilidad de las variables. Si alguna métrica cayera por debajo de un umbral acordado, el equipo revisaría primero la calidad de los datos y las causas del cambio antes de autorizar un nuevo entrenamiento. Cada versión candidata tendría que compararse con la anterior en datos independientes, documentar la aprobación humana y conservar un mecanismo para regresar al modelo previo.

La principal deuda técnica es que los datos corresponden a una muestra estática, sin validación temporal ni evaluación prospectiva. También faltan pruebas sistemáticas de calibración, equidad por segmentos, robustez ante cambios de distribución y costos de intervención. En producción, estos riesgos podrían provocar deterioro silencioso del modelo y decisiones de retención ineficientes.

Como medidas MLOps se propone: versionar datos y código con etiquetas de liberación; establecer pruebas de esquema, nulos y rangos; comparar métricas de producción con una línea base; monitorear drift y desempeño por segmento; evaluar calibración de probabilidades; registrar revisiones humanas y costos; definir criterios de reentrenamiento y reversión; mantener permisos y protección de datos. Antes de cualquier despliegue, se requiere validación institucional y análisis de riesgos.

Conclusiones y reflexión

El desarrollo de esta actividad permitió comprender que un proyecto de inteligencia artificial no termina cuando un algoritmo genera predicciones satisfactorias. Aunque Random Forest presentó mejores resultados globales que la Regresión Logística, el proceso también mostró que las decisiones relacionadas con la preparación de los datos, la selección de métricas y la documentación experimental tienen una influencia importante en la calidad del trabajo.

Uno de los aprendizajes más relevantes fue reconocer que una métrica aislada puede ofrecer una visión incompleta del desempeño. En este caso, Random Forest obtuvo mejores valores de F1 y ROC-AUC, pero la Regresión Logística consiguió una sensibilidad ligeramente superior. Esta diferencia demuestra que seleccionar un modelo requiere comprender el problema que se pretende resolver y las consecuencias de sus posibles errores.

Otro aspecto significativo fue la incorporación de MLflow como herramienta de seguimiento. Conservar los parámetros, resultados y artefactos permitió estructurar el

experimento de manera más ordenada y facilitar su revisión. Desde la perspectiva de gestión de proyectos de inteligencia artificial, esta práctica es especialmente valiosa porque contribuye a mantener continuidad entre las etapas de desarrollo y reduce la pérdida de información técnica.

Finalmente, considero que el principal valor del ejercicio no está únicamente en haber identificado el modelo con mejores indicadores, sino en haber construido un procedimiento documentado que puede revisarse, reproducirse y mejorarse. Como siguiente etapa sería conveniente evaluar nuevos conjuntos de datos, estudiar la estabilidad temporal de los modelos y establecer criterios de seguimiento antes de considerar cualquier aplicación en un entorno bancario real.